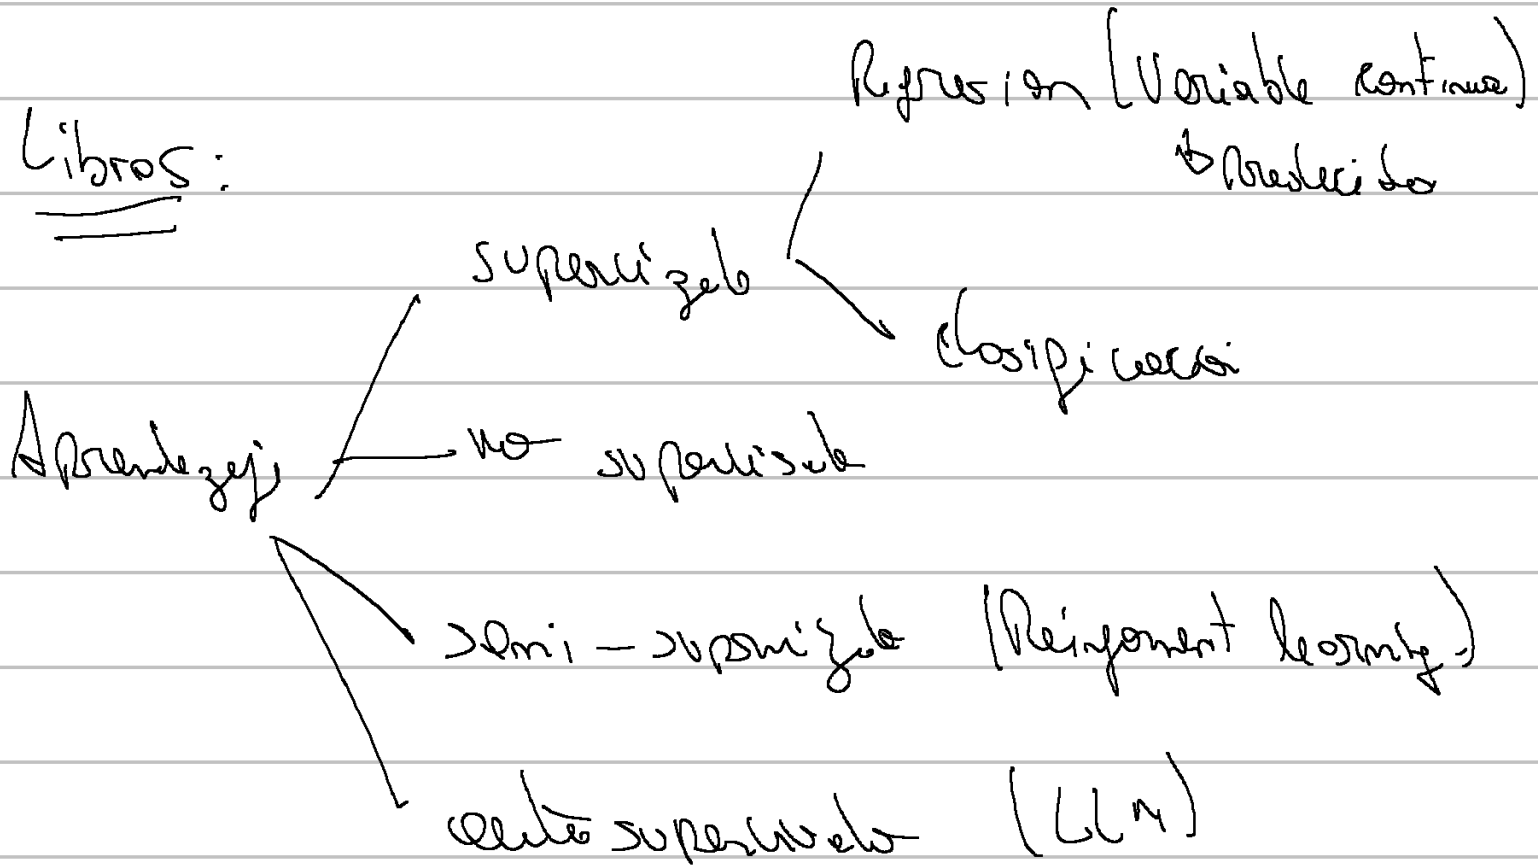


Clase

Clase 11: follow practice
12 evaluación

Libros:



Regresión: las variables predictoras no son
x y son continuas

Clasificación:

train, validation, test
80%.

Normalizar: $\frac{x - \mu}{\sigma}$

Filtro de dados

Underfitting: (sub ajuste) Modelo demasiado simples
($y - \hat{y}$) é grande.

Ex: linha recta para dados com forma de curva.

Sobreajuste

$$E(y - \hat{y})^2 = E[f(x) + \epsilon - \hat{f}(x)]^2.$$

$$= E[f(x) - \hat{f}(x) + \epsilon]^2.$$

$$= E[f(x) - \hat{f}(x)^2 + 2(f(x) - \hat{f}(x))\epsilon + \epsilon^2]$$

$$= E[f(x) - \hat{f}(x)^2] + 2 E[f(x) - \hat{f}(x)] \cdot E(\epsilon) + E(\epsilon^2)$$

Sole xp
 25 em mds
 fixo no
 lma 8A.



$$= f(x) - \hat{f}(x)^2 + 2(f(x) - \hat{f}(x)) \cdot E(\epsilon) + E(\epsilon^2)$$

1
 Vale o
 porque
 $E(\epsilon) = 0$

$$= f(x) - \hat{f}(x)^2 + \overbrace{E(\epsilon^2)}^{\text{Var}(\epsilon)}$$

Nota: $\text{Var} = E[x - E(x)]^2 \Rightarrow \text{Var}(\epsilon) = E(\epsilon - E(\epsilon))^2$
 como $E(\epsilon) = 0 \Rightarrow \boxed{\text{Var}(\epsilon) = E(\epsilon^2)}$

• Descomposición del error. (X es una VA)

$$\text{Error} = (\text{sesp})^2 + \text{Varianza} + \text{Error irreducible.}$$

$$\text{Err}(X) = E(Y - \hat{f}(X))^2$$

$$= \underbrace{f(X) - E(\hat{f}(X))}^{\text{sesp}^2} + E[\underbrace{\hat{f}(X) - E(\hat{f}(X))}_{\sigma^2}]$$

Métricas clasificación

	Real	
	Positivo	Negativo
Positivo	TP	FP
Negativo	FN. Error TI	TN

Error TII

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\frac{\text{Verdes}}{\text{Total}} = \frac{23}{32}$$

$$\text{Precision: } \frac{VP}{VP + FP}$$

Recall

$$\frac{VP}{VP + FN}$$

Costo de un Falso
negativo

$$F1_Score = \frac{2 \text{ Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

• ROC (Receiver Operating Characteristic)

Multiple Regression

$$MSE = \frac{1}{n} \sum (y_i - \hat{f}(x_i))^2.$$

Validation cruzada

Clase

Derivar la resta y el producto β_0 y β_1

Regresson multiple $i, j = 0 \dots n$.

$a, b = 0 \dots p$

$P = n^o$ total de variable

$$Y_i = Y \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \mathbb{R}^{n \times 1} \quad X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix} \begin{matrix} \text{Predictors} \\ \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} \end{matrix}$$

x_{1a}

$$Y = X\beta + \varepsilon$$

$$\Rightarrow \text{RSS}(\beta) = (Y - \hat{Y})^T (Y - \hat{Y})$$

$$= (Y^T - \beta^T X^T) (Y - X\beta)$$

$$= Y^T Y - 2\beta^T X^T Y - \beta^T X^T X \beta$$

Derivamos

$$\frac{\partial \text{RSS}(\beta)}{\partial \beta} = -2X^T Y + 2X^T X \beta = 0$$

$$= X^T X \hat{\beta} = X^T Y \quad \text{Equações normais.}$$

$$(X^T)_{a,i} x_{ib} \hat{\beta}_b = (X^T)_{a,i} y_i \quad \text{p+1 equações.}$$

Ejercicios

Si $Q=0$ verifica que.

$\beta_0 + \beta_a \bar{x}_a = \bar{y}$ } las predicciones están en el hiperplano.

$$\beta = (X^T X)^{-1} X^T y$$

Se pueden invertir las matrices siempre que no haya colinealidad (los valores son el de otros)

$$\text{si } \nabla X^T X \Rightarrow$$

Coefficiente de determinación

$$R^2 = 1 - \frac{RSS}{TSS}$$

$$RSS = \sum (y_i - \hat{y}_i)^2$$

Residual

$$TSS = \sum (y_i - \bar{y})^2$$

total.

Lemma: $TSS = RSS + ESS$. $ESS = \sum (\hat{y}_i - \bar{y})^2$

Explains

Dem: $\sum (y_i - \bar{y}) + \hat{y}_i - \bar{y})^2$

quq: $\sum (y_i - \hat{y}_i) (\hat{y}_i - \bar{y}) = 0$.

$$\sum (y_i - \hat{y}_i) \hat{y}_i = \sum (y_i - \hat{y}_i) \bar{y} = 0.$$

Como note el libro.

$$R^2 = \frac{TSS - RSS}{TSS} = \frac{ESS}{TSS}$$

$$= \frac{\frac{1}{n} \sum (\hat{y}_i - \bar{y})^2}{\frac{1}{n} \sum (y_i - \bar{y})^2}$$

R^2 : que proporción de la varianza se puede explicar con la varianza del modelo

Clase 3

Regressão logística

Maximizar a verossimilhança

, sendo que $y_i = 1$

$$\left. \begin{array}{l} y_i = 1 \quad p_i \\ y_i = 0 \quad 1 - p_i \end{array} \right\} = p_i^{y_i} (1 - p_i)^{1 - y_i}$$

$$\boxed{MLE = \prod p_i^{y_i} (1 - p_i)^{1 - y_i}} \quad \text{função a maximizar}$$

$$\begin{aligned} \ln(MLE) &= \ln \left(\prod p_i^{y_i} (1 - p_i)^{1 - y_i} \right) \\ &= \sum y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i) \end{aligned}$$

$$J(\beta) = - \frac{1}{n} \sum y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)$$

↓ ↑

função a MINIMIZAR

$J(\beta)$ es una función que costea mucho
haber los predicciones equivocadas
(Por qué?).

Resultado, log-loss para la regresión logística
es convexa.

La p_i se relaciona con la β .

Derivada convexidad

$$p_i = \frac{1}{1 + e^{-\sum_{a=0}^p x_{ia} \beta_a}}$$

$$\frac{\partial J}{\partial \beta_a} = \sum_i \frac{\partial J}{\partial p_i} \cdot \frac{\partial p_i}{\partial \beta_a}$$

$$\frac{\partial J}{\partial p_i} = -\frac{1}{n} \left(\frac{y_i}{p_i} - \frac{(1-y_i)}{1-p_i} \right) = \frac{p_i - y_i}{n p_i (1-p_i)}$$

$$\frac{\partial p_i}{\partial \beta_a} = \frac{1}{(1 + e^{\dots})^2} \cdot e^{\dots} \cdot -x_{ia} = -p_i(1-p_i)x_{ia}$$

$$\boxed{\frac{\partial J}{\partial \beta_a} = \frac{1}{n} \sum (p_i - y_i) x_{ia}}$$

$$\frac{\partial^2 J}{\partial \beta_a \partial \beta_b} = \frac{1}{n} \sum \frac{2 p_i}{2 \beta_b} x_{ia}$$

$$= \frac{1}{n} \sum p_i (1 - p_i) x_{ia} x_{ib}$$

Queremos ver se há forma quadrática para as
matrizes covariâncias $\sigma_a \sigma_b > 0$

$$\Rightarrow - \frac{1}{2} \sum_{a,b} \frac{\partial^2 J}{\partial \beta_a \partial \beta_b} \sigma_a \sigma_b$$

$$= \frac{1}{2n} \sum p_i (1 - p_i) \left(\sum_{a=0}^p x_{ia} \sigma_a \right)^2 > 0 //$$

Porque no ho:

$$J = \frac{1}{2n} \sum (y_i - p_i)^2.$$

$$\frac{\partial^2 J}{\partial \beta_a \partial \beta_b} = p_i (1 - p_i) \left[p_i (1 - p_i) - \underbrace{(y_i - p_i)}_{S_i} (1 - 2p_i) \right]$$

$X_i a X_i b$

$$S_i \Big|_{y_i=1} = (1 - p_i) (3p_i - 1) < 0 \quad \text{se } p_i < \frac{1}{3} = 0,33$$

$$S_i \Big|_{y_i=0} = p_i (2 - 3p_i) < 0 \quad \text{se } p_i > \frac{2}{3}.$$

GD

$$\beta_a := \beta_a - \frac{2}{n} \sum (p_i - y_i) x_{ia}.$$

α = learning-rate

SGD

$$\beta_a := \beta_a - 2(p_i - y_i) x_{ia}$$

Roc - AUC

		Actual.	
		IS obese	Not obese
Predicted	IS obese		
	Not obese		

→ De lo cosas que importan
cuanto detecto.

Sensitivity (Recall)

$$\frac{TP}{TP + FN}$$

Prometida V
TOTAL V

$$Precision = \frac{TP}{TP + FP}$$

calidad de lo predicho.
(Que tan bien me dijo como
aserto)

$$Accuracy: \frac{TP + TN}{TOTAL} \quad (\text{engañoso})$$

Roc: Muestra el rendimiento de un clasificador.
Para TODOS los umbrales de clasificación



TPR True positive rate (Tasa de verdaderos positivos).

$$\boxed{VP / (VP + FN)} \quad \text{Recall} \quad TP / (TP + FN) = \text{Recall}$$

De todo lo que era positivo ($VP + FN$),
cuánto fue capaz de predecir.

Es importante cuando el costo de un FN es alto, e.g. detección de cáncer.

$$\boxed{FPR} = \frac{FP}{FP + TN} \Rightarrow \text{Decisiones incorrectas de tratamiento.}$$

close