

$$MSE = \frac{1}{2} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2$$

MSE se puede tomar p/ la data de training pero lo mas interesante es verlo en la data de test para ver como se comporta con data no vista antes.

Entonces podemos separar
Train MSE

$$E(Y_0 - \hat{f}(x_0))^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \text{Var}(\epsilon)$$

Y_0, x_0 son los valores de test.

$\text{Var}()$ es cuanto estimo que cambia \hat{f} cuando lo calculas con otro training set.

Idealmente \hat{f} no debería cambiar mucho si lo entrenas con otro training set.

• Modelos mas flexibles tienen varianza mas alta, esto es porque pequeños cambios en el training set generan grandes cambios en \hat{f} .

• Cuando la curva está muy cerca de la
punto en cambio en un punto hace que
↑ tenga que cambiar mucho.

Bias: El error que se introduce al aproximar f
a un problema Real ($f()$)

• ↑ Flexibilidad \Rightarrow ↑ VAR ↓ BIAS.

Los cambios relativos entre VAR y BIAS determinan
si MSE aumenta o disminuye

Clasificación

accuracy ↑

Proporción de errores al estimar

$$\frac{1}{n} \sum I(y_i \neq \hat{y}_i)$$

$$I(y_i \neq \hat{y}_i) = \begin{cases} 1 & \text{si } y_i \neq \hat{y}_i \\ 0 & \text{si } y_i = \hat{y}_i \end{cases}$$

↓
Error rate

Regression line (supervised learning)


$$y \approx \beta_0 + \beta_1 x$$

↓

modelo
aproximante por.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Parámetros a
determinar.



$$y_i = m x_i + b.$$

$$(y_i, x_i).$$

pendiente

$$y = m x + b \quad \text{ordenado al origen}$$

Minimizar: Cuadrados mínimos

$$e_i = y_i - \hat{y}_i \quad (\text{residuo } i)$$

$$RSS = \sum e_i^2$$

↑

función a minimizar.

Minimizando

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (\text{Demanda})$$

\bar{y}, \bar{x} : promedios de los muestros

Resampling / Cross Validation:
Bootstrap

CV

puede verse afectado el test error.

Test-error-rate : errores al evaluar el modelo en datos
nueva vista

Training-error-rate : el error que se obtiene al evaluar
el modelo contra los datos que se
fueron.

Con CV se estima el test-error con un subconjunto
del training set.

Leave-One-Out Cross Validation

(LOOCV)

K-Fold

Se divide el training set en K partes.

Se toma el primer fold y luego se usan los restantes para entrenar.

Se repite todo el segundo fold una sola vez y así hasta el último.

Se leen los K MSE y se promedian.

4) Clasificación

Probabilidad que una estructura pertenezca a una clase.

Métodos

- Regresión logística
- Naive Bayes
- K NN
- Linear discriminant analysis
- Probabilistic " "
- Poisson regression

La clasificación que se obtiene usando una regresión lineal para predecir una respuesta binaria es la misma que si usamos "linear discriminant analysis" (LDA).

La regresión logística modela la probabilidad de pertenecer a una clase determinada.

Regresión logística

$$P(Y = \text{True} | X)$$

$$p(x)$$

$$Y = \text{True} \quad \text{si} \quad p(x) > 0,5$$

$$p(x) > 0,1 \quad \underline{\text{conservado.}}$$

Modelo

$$p(x) = P(Y=1|X)$$

$$p(x) = \beta_0 + \beta_1 x$$

Si usamos una regresión lineal tenemos el problema de que hay valores menores a 0 o mayores a 1 que no tiene sentido modelarlo como probabilidad.

\Rightarrow Necesitamos la regresión p que devuelva valores entre 0 y 1

$$p(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

$$1 - p(x) = 1 - \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

$$\Rightarrow \frac{1 + e^{\beta_0 + \beta_1 x} - e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}} = \frac{1}{1 + e^{\beta_0 + \beta_1 x}}$$

$$\Rightarrow \text{odd} = \frac{p(x)}{1 - p(x)} = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}} \cdot \frac{1 + e^{\beta_0 + \beta_1 x}}{e^{\beta_0 + \beta_1 x}} = e^{\beta_0 + \beta_1 x}$$

$$\therefore \boxed{\text{odds} = \frac{p(x)}{1-p(x)} = e^{\beta_0 + \beta_1 x}}$$

$\text{odds} \approx 0 \Rightarrow \text{baja probabilidad}$
 $\text{odds} \approx \infty \Rightarrow \text{alta probabilidad}$

Ejemplo 1

1/5 de las personas con odds de 1/4 deficiente.

$$p(x) = 1/5 = 0.2 \Rightarrow \frac{p(x)}{1-p(x)} = \frac{0.2}{1-0.2} = \frac{1/5}{4/5} = \frac{1}{4} = \boxed{\frac{1}{4}}$$

Ejemplo 2

9 de cada 10 con odds de 9 deficiente.

$$p(x) = 9/10 \Rightarrow \frac{9/10}{1/10} = \frac{9}{1} = \boxed{9 = \text{odds}}$$

$$\boxed{p(x) = k \Rightarrow \text{odds} = \frac{k}{1-k}}$$

Recordemos

$$\frac{p(x)}{1-p(x)} = \text{odds} = e^{\beta_0 + \beta_1 x}$$

$$\Rightarrow \ln\left(\frac{p(x)}{1-p(x)}\right) = \beta_0 + \beta_1 x$$

$$\text{log-odd or logit} = \beta_0 + \beta_1 x$$

Para la regresión lineal $y = \beta_0 + \beta_1 x$

β_1 es el cambio promedio de y cuando x cambia en una unidad.

En la logística cualquier x en una unidad cambia
log(odds) en β_1